

Easy Agent / Easy Code 长上下文推理容量评估

500K / 1M 上下文场景下的 8 卡 B200 服务器数量建议

30-32 台 500K 上下文推荐

64-80 台 1M 上下文推荐

300 人 10% 重度用户

一、执行结论

推荐结论：500K 场景按 30-32 台起步；1M 场景按 64-80 台规划

按 3000 员工全员覆盖、10% 重度用户计算：重度用户约 300 人，轻度用户约 2700 人。标准生产活跃请求约为 194 个。若典型请求需要 500K 上下文，建议配置 30-32 台 8×B200；若 1M 上下文常态化在线使用，建议按 64-80 台规划。

30-32 台

500K 推荐配置

64-80 台

1M 推荐配置

5-8

500K 单台舒适并发

2-4

1M 单台舒适并发

这里的“顺畅”按生产稳定性估算，而不是压测极限：P95 首 token 延迟可控、请求不长期排队、单台维护或重启时仍可降级服务。长上下文场景的瓶颈主要是 prefill、KV cache 和调度队列，不是单纯的模型权重能否放进显存。

二、评估假设

项目	假设值	说明
覆盖规模	3000 员工全员覆盖	不是所有员工都会同时触发推理。
用户结构	10% 重度，90% 轻度	重度约 300 人，轻度约 2700 人。
重度用户	15% 活跃 × 2.5 API	程序员、Agent 编排、代码库分析等高并发场景。
轻度用户	3% 活跃 × 1.0 API	问答、文档、轻量自动化等低频场景。
规划活跃请求	约 194 个	$300 \times 15\% \times 2.5 + 2700 \times 3\% \times 1.0$ 。
硬件单元	8×B200 服务器	单机约 1,440GB GPU 显存，作为一个推理调度单元。

关键原则

500K / 1M 上下文不能按普通 32K-64K 的并发经验估算。上下文越长，单台可承载的舒适活跃并发越低，排队和首 token 延迟会更快恶化。

三、两种上下文场景建议

上下文场景	单台舒适活跃并发	标准活跃请求	推荐服务器	建议
500K context	5-8	约 194	30-32 台	可以作为生产主方案，但必须做长请求限流。
1M context	2-4	约 194	64-80 台	不建议所有在线请求默认开放，需独立模型池和队列。

采购建议

如果业务明确需要 500K 上下文：先按 30-32 台 8×B200 做生产规划。如果业务坚持 1M 上下文常态化在线使用：不要低于 64 台，预算允许按 80 台规划更稳。

四、测算逻辑

场景	计算过程	结论
500K context	194 活跃请求 / 7 单台舒适并发 ≈ 28	建议 30-32 台
1M context	194 活跃请求 / 3 单台舒适并发 ≈ 65	建议 64-80 台
冗余策略	至少保留 1-2 台可切换容量	包含在推荐区间内

推荐公式

所需服务器数 = $\text{ceil}(\text{重度用户请求} + \text{轻度用户请求} / \text{单台舒适活跃并发})$ ，再结合弹性冗余。标准生产假设为： $300 \times 15\% \times 2.5 + 2700 \times 3\% \times 1.0 = 193.5$ ，按 194 个活跃请求计算。

敏感性分析：

负载	活跃请求数	500K 推荐	1M 推荐
轻负载	128	20 台	42-56 台
标准生产	194	30-32 台	64-80 台
高峰负载	323	48-56 台	108 台以上

五、推荐部署形态

资源池	500K 方案	1M 方案	策略
主推理池	24-26 台	52-66 台	承接主要 Easy Agent / Easy Code 长上下文请求。
高优先级池	4 台	8-10 台	供程序员、关键用户和高价值任务使用。
冗余/灰度池	2 台	4 台	用于升级、故障接管、模型 AB 测试。

Easy Agent / Easy Code 接入建议：对外统一暴露 OpenAI-compatible endpoint，在网关层做模型路由、并发限流、队列、超时、重试和用户级配额。500K 和 1M 请求应独立队列，避免长上下文请求拖垮普通交互。

推荐控制参数：

参数	建议值
500K context	可作为高配默认，但设置用户级并发上限。
1M context	仅建议白名单、异步任务或独立高配资源池。
max output	2K-4K；避免长上下文叠加超长输出。
调度策略	500K / 1M 独立队列，短请求优先，每用户配额。
观测指标	TTFT、tokens/s、queue wait、KV cache 使用率、GPU 利用率、失败率

六、风险与验证

风险	影响	缓解策略
1M 常态化	成本和排队压力显著上升。	仅对白名单或异步任务开放。
Agent 并行放大	300 名重度用户会贡献主要峰值压力。	设置 maxConcurrent 和用户级配额。
长请求拖垮短请求	普通交互被 500K/1M 请求阻塞。	长短请求分池或分队列。
只看平均吞吐	峰值体验差，用户感知卡顿。	监控 P95/P99 TTFT 和 queue wait。

建议采购路径

如果确定以 500K 为主，建议先落 30-32 台并压测真实 Easy Agent / Easy Code trace。如果 1M 是刚性需求，不建议从 32 台硬撑，直接按 64 台起步并预留扩到 80 台的机柜、电力和网络空间。

七、压测清单

检查项	目标
500K input / 2K output	验证主生产场景的 TTFT、吞吐和排队。
1M input / 2K output	验证极限长上下文场景是否可在线交互。
并发 2 / 4 / 8 / 16 梯度	找到单台 8×B200 的舒适并发。
Easy Agent / Easy Code 真实工作流回放	覆盖工具调用、子任务、重试和多轮会话。
故障演练	重启一台推理节点，验证网关切流和队列恢复。

注：本报告给出的数量是长上下文生产稳定性估算，不是单机理论极限。最终采购前必须用真实 Easy Agent / Easy Code trace 回放压测校准。